

Trabajo Práctico Integrador

Otoño 2026

Introducción

El trabajo práctico consiste en desarrollar un sistema de búsqueda multimodal de imágenes, inspirado en las funcionalidades de **Google Fotos**, donde el usuario ingresa un texto (por ejemplo, “escritorio”) y el sistema devuelve imágenes relevantes.

Para ello se utilizará **CLIP** (*Contrastive Language–Image Pre-training*), un modelo multimodal entrenado con millones de pares texto–imagen. CLIP permite transformar tanto texto como imágenes en **vectores numéricos (embeddings)** dentro de un mismo espacio semántico. Gracias a esto, se pueden comparar consultas en lenguaje natural con imágenes de un dataset de manera directa, midiendo la similitud de sus embeddings.

Dado que los embeddings son vectores de alta dimensión, se requiere una estructura que permita **búsquedas rápidas y eficientes**. Para esto se utilizará **FAISS** (Facebook AI Similarity Search), una librería optimizada para indexar y recuperar vectores mediante métricas de similitud (ej. producto interno o coseno). En el TPI, FAISS se usará como la base de datos vectorial donde se almacenarán los embeddings de todas las imágenes.

La novedad en esta edición es la incorporación de un **enfoque agéntico con LLMs livianos** (por ejemplo, TinyLlama, Phi-3-mini o similar), donde el sistema pueda **planificar, reformular y verificar** la consulta antes de ejecutar la búsqueda. Esto permitirá manejar de forma más robusta los siguientes casos:

- Traducción de consultas en español al inglés (idioma en el que fue entrenado CLIP).
- Expansión con sinónimos o términos relacionados.
- Manejo de negaciones simples (ej. “auto no rojo”, “alguien no contento”).
- Verificación de integridad semántica de la consulta (detección de inconsistencias o reformulaciones defectuosas).

La recuperación de imágenes se realizará combinando **CLIP + FAISS**, y en los casos donde la consulta contenga negaciones o atributos excluyentes se aplicará un **reranking** para penalizar los resultados no deseados.

Requerimiento

En el contexto de una competencia de Kaggle, implementar una notebook que:

- Explore el dataset de imágenes y presente un análisis exploratorio (dimensiones, clases, distribuciones, visualizaciones).
- Genere embeddings globales de las imágenes, indexarlas en FAISS e implemente una búsqueda por texto → imagen (baseline).
- Integre un modelo generativo liviano (ej. TinyLlama) para reformular consultas en lenguaje natural.
- Incorpore una capa agéntica de validación previa a la búsqueda para controlar coherencia e integridad de las consultas.
- Implemente un esquema de reranking que mejore los resultados en casos de negaciones o atributos conflictivos.
- Compare los resultados obtenidos con y sin reformulación, mostrando ejemplos visuales y métricas de recuperación.

Dataset

Para este trabajo práctico se utilizará el dataset **Pascal VOC 2012**, disponible en Kaggle bajo el nombre `pascal-voc-2012-dataset`.

- El dataset contiene miles de imágenes anotadas en diversas clases de objetos comunes.
- Para este TPI se utilizará **exclusivamente** el conjunto de imágenes ubicado en la carpeta:

`pascal-voc-2012-dataset/VOC2012_train_val/VOC2012_train_val/JPEGImages`

- Las etiquetas provistas por el dataset podrán ser utilizadas como referencia para calcular métricas de evaluación, pero no forman parte del pipeline principal de búsqueda.
- Cada grupo deberá realizar un análisis exploratorio (EDA) de estas imágenes, calcular embeddings y usarlos como base para las tareas de búsqueda y comparación de resultados.

Desarrollo del trabajo

El trabajo se divide en tres secciones principales, las cuales deben desarrollarse en una notebook en la plataforma Kaggle y en un informe técnico.

1. Exploración del Dataset

- Cálculo de estadísticas: cantidad total de imágenes, dimensiones, canales, tamaño de archivo.
- Distribución por clases (a partir de etiquetas).
- Visualizaciones: scatter de dimensiones, histogramas de tamaño, barras por clase.
- Clustering de imágenes usando embeddings globales (ej. K-Means, t-SNE, UMAP).

2. Búsqueda Global y con Reformulación Agéntica

- Cálculo de embeddings globales por imagen (ej. CLIP ViT-B/32).
- Indexación en FAISS y recuperación por texto directo (baseline).
- Integración de un LLM liviano para reformulación y control de calidad de consultas:
 - Traducción es $\rightarrow$ en.
 - Sinonimia y normalización semántica.
 - Detección de negaciones.
 - Verificación de integridad de consulta (consistencia semántica y corrección de reformulación).
- Recuperación con consultas reformuladas y variantes generadas por el LLM.
- Registro de trazas de decisión del pipeline (pasos ejecutados, decisiones, y eventuales correcciones).

Lineamiento de enfoque agéntico

Se espera que cada grupo diseñe un flujo con componentes que colaboren entre sí (por ejemplo, detección de idioma, traducción, verificación, planificación de estrategia y reranking), **sin imponer una arquitectura única**. La cátedra evaluará especialmente:

- Que exista una separación clara de responsabilidades entre etapas del pipeline.
- Que las decisiones del sistema sean observables y justificables (trazabilidad).
- Que el sistema sea robusto ante consultas ambiguas, mal traducidas o con negaciones.

3. Reranking y Comparación

- Implementar un esquema de reranking que penalice los términos negativos en las consultas.
- Visualizar resultados comparando baseline vs. reformulación+reranking.
- Discusión de ventajas, limitaciones y posibles mejoras.

4. Evaluación de Resultados

- Definir métricas cuantitativas para analizar y comparar los resultados obtenidos.
- Utilizar las 20 clases provistas por Pascal VOC 2012 como referencia para consultas simples (ej. "dog", "car", "person").
- Diseñar un esquema de evaluación para consultas más complejas. Algunas opciones posibles son:
 - Construir manualmente un subconjunto de imágenes relevantes para ciertos prompts y evaluarse contra esa referencia.
 - Descomponer un prompt complejo en componentes simples y aproximar el ground truth mediante la intersección de resultados parciales (ej. "auto rojo con cielo nublado" $\rightarrow$ "auto rojo" $\cap$ "cielo" $\cap$ "nubes").
- Discutir ventajas, limitaciones y posibles mejoras del esquema de evaluación elegido.

Niveles de Logro

El trabajo contempla distintos niveles de complejidad, que se construyen de manera acumulativa. Para que un nivel se considere alcanzado al 100%, la calidad de la **notebook**, el **informe técnico** y la **defensa oral** de esa parte deben ser correctas, claras y completas. No alcanza únicamente con implementar el código. Para alcanzar un nivel es necesario implementar correctamente lo estrictamente definido en ese nivel. No se pueden combinar items individuales de distintos niveles.

- **Nivel base (Aprobado)** Corresponde a los puntos 1, parte del 2 y el inicio del 4 del *Desarrollo del trabajo*.
 - Análisis exploratorio básico del dataset (estadísticas, visualizaciones simples).
 - Generación de embeddings globales de imágenes con CLIP.
 - Indexación y búsqueda básica en FAISS usando la consulta original del usuario.
 - Evaluación simple con las clases provistas por Pascal VOC 2012.
- **Nivel intermedio (Bueno)** Extiende al nivel base e incorpora el resto del punto 2 y parte del 4.
 - Integración de un LLM liviano para reformular consultas (traducción y sinonimia mínima).
 - Inclusión de un mecanismo de verificación de integridad de consulta antes de recuperar resultados.
 - Comparación documentada entre los resultados del baseline y los de la reformulación.
 - Visualizaciones que ilustren diferencias de desempeño.

- Evaluación extendida con ejemplos de consultas reformuladas.
- **Nivel avanzado (Sobresaliente)** Extiende al nivel intermedio y cubre el punto 3 y el 4 del *Desarrollo del trabajo*.
 - Implementación de reformulación avanzada con múltiples variantes de prompt.
 - Reranking de resultados en consultas con negaciones o atributos excluyentes.
 - Estrategia agéntica explícita con trazas de decisión y análisis de errores por etapa.
 - Análisis exploratorio más profundo (ej. clustering de imágenes).
 - Estudio comparativo o *ablation study* mostrando el aporte de cada componente del sistema (baseline, LLM, reranking).
 - Diseño de un esquema propio de evaluación para prompts complejos (subconjunto anotado o combinación de componentes simples).

Escala de puntaje y cortes

- **Suficiente para aprobado (Nota 6):** $\geq 68/100$ y cumplimiento de todas las condiciones habilitantes de aprobado.
- **Suficiente para promoción (Nota 7):** $\geq 77.7/100$ y cumplimiento de todas las condiciones habilitantes de promoción.

Condiciones habilitantes

Para Nota 6 (Aprobado):

- Baseline CLIP+FAISS funcionando de punta a punta.
- Notebook reproducible en Kaggle con resultados visibles.
- Al menos una comparación simple entre baseline y reformulación.
- Defensa oral con comprensión técnica básica del pipeline.

Para Nota 7 (Promoción):

- Cumplir todo lo requerido para Nota 6.
- Implementar explícitamente **enfoque agéntico** (módulos/etapas con responsabilidades diferenciadas).
- Incluir **validación de integridad de consulta** previa a la búsqueda y evidenciar su impacto.
- Presentar trazas o logs de decisiones para consultas complejas (idioma, reformulación, negaciones, estrategia).
- Mostrar evaluación comparativa consistente (incluyendo casos complejos) y justificar decisiones de diseño.

Competencia en Kaggle

El trabajo se organizará como una **competencia en Kaggle**, donde cada grupo deberá entregar sus resultados de búsqueda.

La competencia oficial de este año se encuentra en: <https://www.kaggle.com/t/c08a7b4815a64b6f957dbd2b25bf0d8d>.

La evaluación en Kaggle se hará en base a una métrica simple definida por la cátedra. La tabla de puntajes de Kaggle no determinan la aprobación o desaprobación del TPI. La tabla funciona únicamente como una referencia comparativa para fomentar la competencia entre equipos.

Cronograma

- **Presentación del TPI (reporte, notebook y solución kaggle):** domingo 14/06/2026 a las 23:59 hs.
- **Entrega de notebook:** Debe compartirse en Kaggle con el usuario `martingra` antes del domingo 14/06/2026 a las 23:59 hs.
- **Defensas orales:** A confirmar (25/06/2026 - 01/07/2026)

Entregables

- Reporte técnico en **Markdown (.md)** (breve, técnico, claro), con imágenes, tablas y figuras cuando corresponda. [UV]
- Notebook de Kaggle con el desarrollo completo. [UV y Kaggle]
- Archivos auxiliares (ej. embeddings guardados, metadatos). [Kaggle]
- **No se acepta ningún otro formato de reporte técnico** (por ejemplo: PDF, DOCX, Google Docs exportado, etc.).

Requisitos de la Notebook

La notebook en Kaggle constituye el soporte técnico del trabajo. No se evalúa la calidad del código en sí mismo, sino su organización, claridad y reproducibilidad. Los puntos clave a considerar son los siguientes:

- La notebook debe ser **completamente reproducible en Kaggle**, sin requerir configuraciones adicionales ni archivos externos distintos a los provistos por la cátedra o generados durante la propia ejecución. Además, todos los resultados deben poder reproducirse de forma idéntica: en los casos donde exista aleatoriedad (por ejemplo, en inicializaciones, muestreos o algoritmos de clustering), se debe fijar una **semilla aleatoria** para garantizar la repetibilidad de los experimentos.

- Debe estar **bien estructurada en secciones**, utilizando celdas de Markdown con explicaciones generales que acompañen cada parte del desarrollo.
- Evitar comentarios redundantes o automáticos generados por modelos de lenguaje; la redacción debe ser propia, clara y concisa.
- El código debe ser entendible para cualquier lector, aunque no se califica la calidad de programación en términos de estilo o eficiencia.
- La notebook se utilizará como **referencia técnica** para verificar que se haya implementado lo indicado en el informe. El **reporte técnico es el documento principal de evaluación**, y debe corresponderse exactamente con la implementación presentada en la notebook.
- Cada integrante del grupo debe estar en condiciones de **explicar el código durante la defensa oral**.
- Es recomendable incluir visualizaciones claras y ejemplos ilustrativos que permitan validar el funcionamiento paso a paso (EDA, baseline, reformulación, reranking).
- Al guardar la notebook, debe hacerse **incluyendo todas las salidas**, de modo que pueda seguirse fácilmente sin necesidad de reejecutar el código.
- El archivo debe nombrarse siguiendo el formato: TPI_IA_2026P_[nro_de_grupo].
- No se permite modificar la notebook luego de la fecha de entrega.

Estructura sugerida del Reporte Técnico (Markdown .md)

El reporte debe ser breve, técnico y enfocado en los resultados. No se trata de una monografía ni de un repaso teórico. Cada sección debe corresponderse exactamente con lo implementado en la notebook. El reporte debe entregarse en un archivo **.md** e incluir imágenes, tablas, figuras y enlaces internos/externos cuando aporten claridad técnica. **No se aceptarán reportes en formatos distintos de Markdown (.md).**

1. Portada

- Nombre de la materia y de la cátedra.
- Cuatrimestre y año.
- Número y nombres de los integrantes del grupo.

2. Análisis del Dataset (EDA)

- Estadísticas básicas (cantidad de imágenes, clases, dimensiones).
- Visualizaciones relevantes (histogramas, ejemplos representativos).
- Resultados del clustering exploratorio.

3. Metodología

- Descripción del pipeline implementado (baseline, reformulación con LLM, validación de integridad y reranking).
- Decisiones de diseño (parámetros de FAISS, prompts al LLM, pesos de penalización, etc.).
- Justificación breve de cada decisión tomada.

4. Resultados

- Ejemplos visuales de búsquedas baseline vs. con reformulación.
- Comparaciones visuales de distintas configuraciones cuando corresponda.
- Resultados del esquema de reranking para negaciones.

5. Discusión y Análisis Crítico

- Qué funcionó bien y por qué.
- Qué intentos no funcionaron y posibles explicaciones.
- Limitaciones del enfoque y observaciones generales.

6. Trabajo Futuro

- Qué experimentos o mejoras les hubiera gustado implementar con más tiempo o recursos.

Formato de `submission.csv` (Kaggle)

La entrega en Kaggle debe consistir en un archivo `submission.csv` con **una fila por consulta** (q1 a q40) y las siguientes columnas:

- **qid**: identificador de la consulta, en el formato q1, q2, ..., q40.
- **preds**: exactamente **10** *image_id* predichos, **sin extensión** (.jpg), separados por punto y coma ; y en el **orden de ranking** (mejor a peor).

Requisitos y validaciones:

1. Cada fila debe contener **exactamente 10** IDs en **preds**.
2. Los IDs deben ser **únicos** dentro de la fila (no se permiten duplicados).
3. Los IDs se obtienen del nombre de archivo de VOC (por ejemplo, 2007_000027.jpg → 2007_000027).
4. Separador: ; (punto y coma). No agregar un ; al final.
5. El **qid** **debe existir** para todas las consultas del conjunto (q1..q40) y aparecer **una sola vez** cada uno.

Notas:

- El **orden importa**: la métrica computa *Average Precision* @10, por lo que conviene ordenar **preds** del más relevante al menos relevante.
- Para las consultas q1..q20 (clases VOC), el “*ground truth*” se toma de las anotaciones oficiales de Pascal VOC 2012. Para q21..q40 se usa el conjunto de referencia provisto en la **solution.csv** de la cátedra.
- El archivo **submission.csv** no debe incluir columnas adicionales (por ejemplo, **row_id**).

Errores comunes a evitar:

- Menos de 10 predicciones en **preds** para alguna fila.
- IDs con extensión (por ej., 2007_000027.jpg) o con espacios.
- Duplicar un mismo ID dentro de las 10 posiciones.
- Usar separadores distintos de ; (por ejemplo, comas).

Reglas

- El trabajo y la notebook deben ser reproducible y ejecutable en Kaggle sin recursos extra.
- No se permite modificar la notebook luego de la fecha de entrega.
- Toda manipulación artificial de la salida para mejorar el score será motivo de desaprobarción.

Grupos

El trabajo se realiza en grupos de hasta 4 personas.

Presentación Oral

- Las presentaciones orales son una instancia de defensa y justificación del trabajo de no más de 10 minutos de duración.
- Deberán responder preguntas puntuales en donde se pedirá explicar las decisiones técnicas y justificar su enfoque.